Introducción al Machine Learning

Quinta lista de ejercicios

Selección de variables y generalización

Universidad El Bosque
Programa de Matemáticas y Estadística
Semestre 2026–2

Datos. El archivo `hitters.csv` contiene estadísticas de 263 jugadores de béisbol. La variable `Salary` es el salario (en miles de dólares); las otras 19 columnas son predictoras. Las variables `League`, `Division` y `NewLeague` ya están codificadas como 0 o 1.

Partición. Use `train_test_split`, siempre con `random_state=31`, en dos etapas:

1. Separe 120 jugadores para desarrollo y 143 para prueba.
2. Divida los 120 de desarrollo en 50 para entrenamiento y 70 para validación.

Use exclusivamente entrenamiento y validación en los ejercicios 1–3. Reserve la prueba para el ejercicio 4.

Trabaje con regresión lineal con intercepto. Calcule el riesgo cuadrático mediante una función propia:

$$\widehat{R}_S(h) = \frac{1}{|S|} \sum_{i \in S} \big(y_i - h(x_i)\big)^2.$$

Ejercicio 1. Modelo completo [1,5 puntos]

Ajuste una regresión lineal con las 19 variables.

(a) Calcule el riesgo en entrenamiento y validación.

(b) Registre ambos valores.

Ejercicio 2. Selección estadística de variables [3 puntos]

(a) Calcule la correlación de Pearson de cada variable con `Salary`, usando solo entrenamiento. Ordénelas por el valor absoluto de su correlación.

(b) Ajuste una regresión con las siete variables de mayor correlación. Calcule los riesgos de entrenamiento y validación.

(c) En la regresión completa, obtenga el valor p de la prueba t de cada coeficiente. Seleccione las variables con $p < 0{,}05$, ajuste una regresión con ellas y calcule ambos riesgos.

(d) Reporte las variables seleccionadas por cada criterio y compare los riesgos de los modelos obtenidos.

Ejercicio 3. Selección hacia adelante [3 puntos]

Comience con una sola variable: elija la que produzca el menor riesgo de entrenamiento. Después agregue, una por una, la variable que más disminuya ese riesgo, sin retirar las anteriores. Continúe hasta utilizar las 19 variables.

(a) Construya una tabla con el número de variables, la variable agregada y los riesgos de entrenamiento y validación.

(b) Grafique los dos riesgos según el número de variables.

(c) Elija el modelo con menor riesgo de validación e indique qué variables utiliza.

Ejercicio 4. Comparación final [2,5 puntos]

Elija uno de los cuatro modelos con base en los riesgos de validación. Después, evalúe todos los modelos en el conjunto de prueba.

(a) Indique qué modelo eligió y con cuál riesgo de validación.

(b) Complete la siguiente tabla:

Modelo	Variables	Riesgo train	Riesgo validación	Riesgo prueba
Todas las variables				
Mayor correlación				
Pruebas t				
Selección hacia adelante				

(c) ¿Qué modelo tiene el menor riesgo de entrenamiento y cuál tiene el menor riesgo de prueba? ¿Coinciden?

(d) ¿El modelo escogido con validación fue el que tuvo menor riesgo de prueba? Responda con los valores de la tabla.

Entrega. Repositorio de GitHub con `README.md`, `requirements.txt`, código reutilizable en `src/`, un cuaderno en `notebooks/`, y las tablas y gráficas solicitadas. El cuaderno debe poder ejecutarse desde un kernel reiniciado. **Total: 10 puntos.**